



**UNIVERSITATEA  
TEHNICĂ  
DIN CLUJ-NAPOCA**

---

**Reinforcement Learning**

*Inteligența Artificială*

---

Autori: Laura-Luisa Voicu

Grupa: 30236

FACULTATEA DE AUTOMATICA  
SI CALCULATOARE

11 Ianuarie 2024

# Cuprins

<b>1</b>	<b>Introdúcere</b>	<b>2</b>
1.1	Overview	2
1.1.1	Despre Reinforcement Learning	2
1.2	MDP - Markov Decision Process	2
1.3	MDPs - Instrucțiuni	2
<b>2</b>	<b>Question 1: Value Iteration</b>	<b>2</b>
2.1	Update State	2
2.2	Comenzi de rulare	3
2.3	Cod	3
2.4	Dificultati la implementare	4
<b>3</b>	<b>Question 3: Policies</b>	<b>4</b>
3.1	Context	4
3.2	Cerinta	5
3.3	Comenzi de rulare	5
3.4	Cod	5
3.5	Justificari	6
<b>4</b>	<b>Question 5: Q-Learning</b>	<b>8</b>
4.1	Context	8
4.2	Comenzi de rulare	8
4.3	Cod	8

# 1 Introducere

## 1.1 Overview

### 1.1.1 Despre Reinforcement Learning

Reinforcement Learning = tehnica de invatare automata prin care un software e invatat sa ia decizii pentru a obtine rezultatele cele mai optime.

Actiunile software-ului ce contribuie la atingerea obiectivului vor fi intarite, in timp ce actiunile ce indeparteza obiectivul sunt ignorate.

Reinforcement Learning - types:

1. Passive Reinforcement Learning: how to learn from already given experiences
  - (a) Model-based: modelul MDP invata din experiente, dupa care rezolva MDP-ul
  - (b) Model-free:
    - i. Value learning: invata valori dintr-un policy fix
    - ii. Q Learning: invata Q valori din policy-ul optimal
2. Active Reinforcement Learning: hot to collect new experiences
3. Approximate Reinforcement Learning: to handle large state spaces

## 1.2 MDP - Markov Decision Process

Reinforcement Learning foloseste MDP

- Are un set de stari
- Are un set de actiuni per stare
- Are un model  $T(s,a,s')$
- Are o functie de recompensa  $R(s,a,s')$

## 1.3 MDPs - Instructiuni

Rulare Gridworld (foloseste arrow keys)

```
python3 gridworld.py -m
```

```
# agentii se muta random  
python3 gridworld.py -g MazeGrid
```

In Gridworld MDP pozitiile sunt reprezentate ca si coordonate (x,y). Default, recompensa este 0; ea poate fi schimbata cu optiunea -r.

# 2 Question 1: Value Iteration

## 2.1 Update State

Pentru a update starea curenta, se va folosi formula:

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_k(s')]$$

Figura 1: Update next state

Q1 presupune scrierea unui value iteration agent ce reprezinta un **offline planner**, nu un agent de reinforcement learning.

Clasa ValueIterationAgent ca un MDP si ruleaza iteratiile de atatea ori cat a fost specificat.

Se vor computa k pasi ce estimeaza valoarea optima  $V_k$  (in metoda **runValueIteration**). E necesara implementarea :

- `computeActionFromValue(state)` - are rolul de a computa cea mai buna actiune corespunzatoare valorii din `self.values`
- `computeQValueFromValues(state, action)` - returneaza Q-value al tuplei (state, action) corespunzatoare valorii din `self.values`.

## 2.2 Comenzi de rulare

```
python3 gridworld.py -a value -i 100 -k 10
```

```
python3 gridworld.py -a value -i 5
```

#Autograder:

```
python3 autograder.py -q q1
```

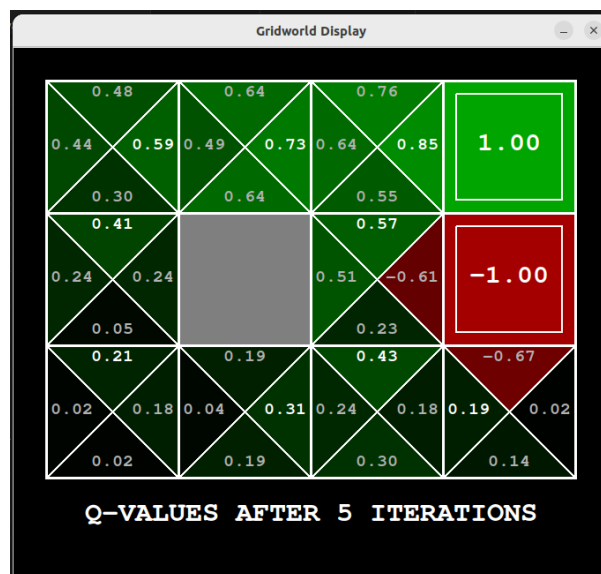


Figura 2: Value Iteration

## 2.3 Cod

:

```

1 class ValueIterationAgent(ValueEstimationAgent):
2
3     def runValueIteration(self):
4         for _ in range(self.iterations):
5             aux_values = util.Counter()
6             for state in self.mdp.getStates():
7                 if not self.mdp.isTerminal(state):

```

```

8         actions = self.mdp.getPossibleActions(state)
9         max_value_state = self.computeQValueFromValues(state, actions[0])
10        for action in actions:
11            value = self.computeQValueFromValues(state, action)
12            if value > max_value_state:
13                max_value_state = value
14            aux_values[state] = max_value_state
15        else:
16            aux_values[state] = 0
17        self.values = aux_values
18
19
20    def computeQValueFromValues(self, state, action):
21
22        #V(k+1)(s) = max(Sum(T(s,a,s')*[R(s,a,s') + gama*V(k)(s')]))
23        # s' - noua stare, V - values, R - reward, gama - factor discount
24        q_value = 0
25        R = self.mdp.getReward
26        gama = self.discount
27        V = self.values
28        all_states_probs = self.mdp.getTransitionStatesAndProbs(state, action)
29        for new_state, prob in all_states_probs:
30            q_value += prob * ( R(state, action, new_state) + gama * V[new_state] )
31        return q_value
32
33
34    def computeActionFromValues(self, state):
35        if self.mdp.isTerminal(state):
36            return None
37
38        # state neterminal
39        policies = [(self.computeQValueFromValues(state, action), action) for action in self.mdp.getPossibleActions(state)]
40
41        # returnam cheia pentru care policy e maxim
42        return max(policies, key = lambda x : x[0])[1]

```

## 2.4 Dificultati la implementare

- Intelegerea conceptelor: MDP, Reinforcement Learning, Values / QValues
- Integrarea functiilor deja existente prezentate pentru MDP (getTransitionStatesAndProbs, etc.)
- Integrarea efectiva a functiei prezentate mai sus pentru calculul urmatoarei stari.

## 3 Question 3: Policies

### 3.1 Context

**DiscountGrid** - Ce stare terminala alegem?

Exista 2 tipuri de path-uri:

- Risk the cliff (1) - mai scurte dar risca sa castige un payoff negativ mai mare.
- Avoid the cliff (2) - mai lungi dar e mai putin probabil sa gastige payoff negativ mare.




Figura 3: Cliffs

### 3.2 Cerinta

Setarea discount-ului, noise-ului si a reward-ului astfel incat sa se produca policy-ul optimal pentru diverse tipuri.

Optimal policy types

- Prefer the close exit (+1), risking the cliff (-10)
- Prefer the close exit (+1), but avoiding the cliff (-10)
- Prefer the distant exit (+10), risking the cliff (-10)
- Prefer the distant exit (+10), avoiding the cliff (-10)
- Avoid both exits and the cliff (so an episode should never terminate)

### 3.3 Comenzi de rulare

```
python3 gridworld.py -g DiscountGrid -a value --discount [YOUR_DISCOUNT] --noise [YOUR_NOISE]
```

#Autograder:

```
python3 autograder.py -q q3
```

### 3.4 Cod

```
1 def question3a():
2     answerDiscount = 0.5
3     answerNoise = 0
4     answerLivingReward = -1
5     return answerDiscount, answerNoise, answerLivingReward
6
7 def question3b():
8     answerDiscount = 0.5
```

```

9      answerNoise = 0.25
10     answerLivingReward = -1
11     return answerDiscount, answerNoise, answerLivingReward
12
13 def question3c():
14     answerDiscount = 1
15     answerNoise = 0
16     answerLivingReward = -1
17     return answerDiscount, answerNoise, answerLivingReward
18
19 def question3d():
20     answerDiscount = 0.5
21     answerNoise = 0.5
22     answerLivingReward = 0.5
23     return answerDiscount, answerNoise, answerLivingReward
24
25 def question3e():
26     answerDiscount = 1
27     answerNoise = 0
28     answerLivingReward = 1
29     return answerDiscount, answerNoise, answerLivingReward
30
31 def question8():
32     answerEpsilon = None
33     answerLearningRate = None
34     return answerEpsilon, answerLearningRate
35

```

### 3.5 Justificari

- Question3a
  - answerDiscount: 0.5 - accent moderat pe reward imediat
  - answerNoise: 0 - actiuni cunoscute, nu random
  - answerLivingReward: -1 penalizarea agentului daca continua
  - concluzie: Agentul e focusat pe reward imediat si primeste penalizare daca continua. Setarile implica tinderea spre castiguri de scurta durata, dar adoptand o abordare prudenta (answerNoise e 0).
- Question3b
  - answerDiscount: 0.5 - accent moderat pe reward imediat
  - answerNoise: 0.25 - pot aparea decizii random in actiunea agentului
  - answerLivingReward: -1 - penalizarea agentului daca continua
  - concluzie: Agentul manifesta un echilibru intre recompensele imediate si cele indepartate.
- Question3c
  - answerDiscount: 1 - trateaza in mod egal recompensele imediate si cele indepartate
  - answerNoise: 0 - nu exista actiuni random in actiunile agentului.
  - answerLivingReward: -1 - penalizarea agentului daca continua

- concluzie: Agentul acorda aceeași prioritate recompenselor imediate și îndepărtate, dar absența Noise-ului poate duce la abordare prudentă întrucât acțiunile viitoare sunt cunoscute.
- Question3d
  - answerDiscount: 1 - tratează în mod egal recompensele imediate și cele îndepărtate
  - answerNoise: 0.5 - apar decizii random în acțiunea agentului
  - answerLivingReward: 0.5 - se oferă o recompensă pozitivă pentru existența continuă a agentului
  - concluzie: Agentul explorează mai mult și este mai dispus la riscuri.
- Question3e
  - answerDiscount: 1 - tratează în mod egal recompensele imediate și cele îndepărtate
  - answerNoise: 0 - acțiuni cunoscute, nu random
  - answerLivingReward: 1 - se oferă o recompensă pozitivă pentru existența continuă a agentului
  - concluzie: Agentul are o existență prelungită, iar recompensele îndepărtate și imediate sunt tratate în mod egal.



Figura 4: Values






Figura 5: QValues

## 4 Question 5: Q-Learning

### 4.1 Context

Agentul nu invata efectiv din experienta, ci doar din modelul MDP. Cand agentul interactioneaza cu environment-ul, el doar urmeaza policy-urile setate.

Agentul Q-learning invata din incercarile si erorile interactiunilor cu environmen-ul prin metoda **update**.

### 4.2 Comenzi de rulare

```
python3 gridworld.py -a q -k 5 -m
```

```
#Autograder:
python3 autograder.py -q q5
```

### 4.3 Cod

```
1 class QLearningAgent(ReinforcementAgent):
2
3     def __init__(self, **args):
4         self.values = util.Counter()
5
6     def getQValue(self, state, action):
7         return self.values[state, action]
8
9     def computeValueFromQValues(self, state):
10        actions = self.getLegalActions(state)
```

```

11         if not actions:
12             return 0
13         return self.getQValue(state, self.getPolicy(state))
14
15     def computeActionFromQValues(self, state):
16         actions = self.getLegalActions(state)
17         if not actions:
18             return 0
19         return max(actions, key=lambda action: self.getQValue(state, action))
20
21     def getAction(self, state):
22         legalActions = self.getLegalActions(state)
23         action = None
24         return action
25
26     def update(self, state, action, nextState, reward):
27         newValue = (1 - self.alpha) * self.getQValue(state, action) + self.alpha * (reward +
28         self.values[state, action] = newValue
29
30     def getPolicy(self, state):
31         return self.computeActionFromQValues(state)
32
33     def getValue(self, state):
34         return self.computeValueFromQValues(state)
35
36
37

```